

Reto Integrador – Coordinación Semafórica Responsiva mediante Sistemas Multiagente



**Tecnológico
de Monterrey**

Equipo #6

Alejandro Martínez Páez - A01286707

Gabriela García Velásquez - A01770989

Mariana Hernández Jiménez -A00841920

Paola Mireles Ochoa - A01753439

TC2032. Diseño de agentes inteligentes (Grupo 301)

Docente:

Alfredo Alan Flores Saldivar

13 de Junio de 2026

Monterrey, Nuevo León

Índice

1. Introducción

- 1.1 Movilidad Urbana
- 1.2 Planteamiento del Problema
- 1.3 Objetivos
- 1.4 Caso de Estudio

2. Metodología

- 2.1 Modelación de Agentes Inteligentes
- 2.2 Método de Toma de Decisiones con Q-Learning
- 2.3 Estrategia de Coordinación para la Onda Verde

3. Resultados

- 3.1 Modelado del Entorno y del Corredor
- 3.2 Comparación Cuantitativa de Escenarios

4. Discusión y Análisis

5. Conclusiones y Trabajo Futuro

- 5.1 Conclusiones
- 5.2 Trabajo Futuro

Referencias

Anexos

- Anexo A. Presentación
- Anexo B. Código Fuente
- Anexo C. Material Complementario
- Anexo D. Repositorio del Proyecto

1. Introducción

1.1 Movilidad Urbana

El crecimiento urbano acelerado ha causado niveles de congestión vehicular que afecta directamente la productividad económica, la calidad de vida y el medio ambiente en las ciudades latinoamericanas (Intriago-Pazmiño et al., 2023; Li et al., 2020, como se citó en Intriago-Pazmiño et al., 2023). La congestión ocurre cuando el volumen de vehículos supera la capacidad de la infraestructura vial, generando flujos irregulares, mayor consumo de combustible y emisiones de gases de efecto invernadero (Mamani-Quispe et al., 2022). Ante esto, los Sistemas Inteligentes de Transporte (ITS) ofrecen mecanismos de gestión dinámica del tráfico sin requerir nueva infraestructura. Dentro de este enfoque, la coordinación semafórica mediante offsets sincronizados permite crear progresiones vehiculares continuas, conocidas como onda verde, que reducen paradas y tiempos de viaje en corredores urbanos (Gobierno de Mendoza, 2025). La incorporación de aprendizaje por refuerzo en sistemas multiagente amplía estas capacidades al permitir que los semáforos aprendan políticas de control adaptativas a partir de la interacción con su entorno (Bouktif et al., 2023).

1.2 Planteamiento del Problema

El corredor Av. Fernando García Roel, en la zona del Distrito Tec del Tecnológico de Monterrey (Campus Monterrey), concentra una demanda vehicular elevada con alta variabilidad temporal. Los semáforos operan con planes de tiempos fijos que no se adaptan a las fluctuaciones del tráfico, lo que rompe la progresión vehicular, incrementa las paradas y satura de forma consecutiva los cuatro cruces críticos del corredor, afectando la movilidad de residentes y comunidad universitaria. Sin coordinación dinámica entre intersecciones, cualquier mejora puntual en un cruce no se traduce en beneficio sistémico; la congestión persiste y se agrava conforme aumenta la demanda.

1.3 Objetivos

Objetivo General: Diseñar e implementar un Sistema Multiagente (SMA) descentralizado que coordine las fases semafóricas de las cuatro intersecciones del corredor Av. Fernando García Roel para evaluar la viabilidad de una onda verde responsiva y comparar su desempeño frente a esquemas de coordinación fija y sin coordinación.

Objetivos Específicos:

- Modelar vehículos y semáforos como agentes autónomos que perciben su entorno y cooperan para mantener la sincronización del corredor.
- Calcular los offsets semafóricos teóricos a partir de las distancias reales entre intersecciones y una velocidad de sincronía de 40 km/h.
- Implementar un algoritmo de Q-Learning que permita a cada agente ajustar dinámicamente su offset minimizando colas vehiculares.
- Generar y analizar el diagrama espacio-tiempo del corredor para evaluar la progresión vehicular y el ancho de banda de la onda verde.

- Comparar cuantitativamente el desempeño del SMA bajo tres escenarios: sin coordinación, coordinación manual y Q-Learning.

1.4 Caso de Estudio

El caso de estudio abarca cuatro intersecciones semaforizadas sobre Av. Fernando García Roel: Int. 02 (García Roel – Junco de la Vega), Int. 03 (García Roel – Ahuehuetes/Los Nogales), Int. 04 (Cantú Leal – García Roel – Luis Elizondo) e Int. 05 (Ricardo Covarrubias – Blvd. Primavera). Las distancias reales entre cruces consecutivos, obtenidas de Google Maps, son 193.8 m, 386.2 m y 385.4 m, con un recorrido total de 965 m, de inicio a fin. Los vehículos cuentan con una velocidad máxima aleatoria en un rango de 9 a 13 m/s (equivalente a 32 - 47 km/hr), por tratarse de una zona urbana escolar. Los ciclos semafóricos base se establecieron entre 140 y 160 s. La simulación empleó curvas de Bézier para modelar trayectorias realistas, un diccionario TRAJECTORIES para indexar rutas y un criterio de producto punto (> 0.65) para gestionar interacciones entre flujos opuestos. Los volúmenes y relaciones origen–destino corresponden a datos reales proporcionados por SEMEX, socio formador del proyecto. Se asume que los flujos modelados son representativos del período de máxima demanda y que la geometría de los cruces permanece constante durante el horizonte de simulación.

2. Metodología

Esta sección detalla el procedimiento seguido para la realización e implementación de la propuesta para los cruces semafóricos analizados. A continuación se describen los métodos utilizados y la estructura seguida para la construcción de agentes y del entorno.

2.1 Modelación de Agentes Inteligentes

El modelo desarrollado está fuertemente basado en la integración de un Sistema Multi-Agente (SMA), en donde múltiples entidades interactúan de manera autónoma en un entorno con la finalidad de optimizar el flujo vehicular a lo largo de todo el corredor real. Para la definición de este sistema se identificaron dos tipos de agentes principales: los vehículos y los semáforos.

Agentes Vehículo

Cada vehículo es modelado como un agente autónomo que es capaz de reaccionar a su entorno de manera local. Las características principales con las que cuentan este tipo de agentes son las siguientes:

- **Origen y ruta (destino):** Cada vehículo tiene un punto de entrada y de salida en la simulación, los cuáles están definidos de forma probabilística utilizando las tasas de demanda de vehículos proporcionadas que están calibradas a ciertos horarios. Los orígenes son los puntos de entrada, los cuáles se identifican con letras (B, D, E, G, I, O, R, P, M) y se define una tasa de inyección diferente para modelar la demanda real que tiene cada uno de estos puntos.

- **Waypoints:** Para representar la trayectoria de cada vehículo se definieron waypoints georreferenciados que utilizan coordenadas métricas. Estas fueron realizadas utilizando curvas de Bézier cúbicas y cuadráticas para replicar los carriles de todo el corredor. La distancia acumulada para cada agente se calcula y almacena al instanciar el agente.
- **Estado:** El agente mantiene un estado interno que registra si está activo, el número de paradas que ha realizado y su estado en el frame anterior para contabilizar los eventos de parada y que no sea redundante.
- **Velocidad:** Los vehículos cuentan con una velocidad máxima aleatoria en un rango de 9 a 13 m/s equivalente a 32 - 47 km/hr. Esto da una mayor representación de la variabilidad de conducción y hace que la velocidad actúe según el entorno.

Otra parte importante de este tipo de agentes es el comportamiento de movimiento que tienen al interactuar con otros agentes y con los semáforos. Por una parte, el protocolo de negociación anticollisiones evalúa si algún vehículo está a 8 metros al frente del agente. Aquí se calcula el producto punto entre el vector de dirección del agente y el vector hacia el vehículo vecino con la finalidad de determinar si el conflicto está ocurriendo en la dirección del avance. En caso de que el valor sea mayor a 0.65, entonces el agente detecta al vecino como una amenaza. Si van en diferentes rutas, el agente con menor progreso de su ruta cede y si empatan se utilizan sus identificadores como desempate (el menor frena).

Por otra parte, el control por semáforo se considera en el caso en el que no exista un conflicto de colisiones. Si el semáforo de la ruta de algún agente se encuentra en rojo o amarillo, se calcula la distancia y a partir de 22.5 metros, el vehículo empieza a disminuir su velocidad gradualmente hasta frenarse. En el caso en que se encuentre muy cerca, la velocidad se fija en cero. Para los semáforos en verde, los vehículos aceleran a razón de 0.25 m/s hasta que alcanzan su velocidad máxima.

Agentes Semáforos

Estos son clave para gestionar de manera autónoma el ciclo de fases de la intersección. Cada intersección del corredor cuenta con su propio agente semafórico. Las variables observadas por cada uno de estos agentes son las siguientes.

- El estado interno de cada semáforo del cruce.
- La cola del semáforo vecino anterior para la parte cooperativa.
- El conteo de los vehículos detenidos en la zona de influencia de cada semáforo.

Cada semáforo individual tiene tres estados que corresponden a los colores rojo, amarillo y verde. Los agentes semafóricos gestionan un ciclo de fases secuencial en donde uno de los semáforos está en verde mientras que los demás permanecen en rojo, luego, se cambia a amarillo y hay un breve periodo de todo rojo antes de pasar a la siguiente fase. Estas decisiones fueron tomadas al observar que no había dos posibles semáforos compatibles en una misma intersección y que era necesario el periodo de todo rojo para evitar colisiones en un escenario realista.

El agente semafórico puede decidir si avanzar a la siguiente subfase entre verde → amarillo → todo rojo → siguiente fase verde. También en la versión con Q-Learning puede ajustar el offset del ciclo para alinearse a la onda verde del corredor.

Entorno

El entorno realizado representa el corredor urbano entre las intersecciones de Junco de la Vega / Fernando García Roel, Ahuehuetes / Los Nogales, Luis Elizondo/ Covarrubias y Primavera, ubicadas en la zona alrededor de Distrito Tec en el municipio de Monterrey, Nuevo León. Se utilizaron coordenadas GPS que fueron convertidas a un sistema métrico con la siguiente aproximación plana:

$$x = R \cdot \Delta lon \cdot \cos(lat_0) \quad y = R \cdot \Delta lat$$

$$\text{Donde } R = 6,378,137 \text{ m}$$

Con esto las distancias reales obtenidas son

- JDLV → Ahuehuetes: 193.8 m
- Ahuehuetes → Luis E.: 285 m
- Luis E. → Primavera: 386.2 m
- Distancia total aproximada: 965 m

El entorno muestra una red vial mediante 14 trayectorias nombradas por origen y destino, las cuales son organizadas en 9 grupos de color según el acceso. Cada una es un conjunto de waypoints que definen el recorrido de los vehículos a lo largo del corredor. El entorno además registra información del estado de los 14 semáforos.

2.2 Método de Toma de Decisiones con Q-Learning

El método para la toma de decisiones seleccionado para los agentes semafóricos es el Aprendizaje por Refuerzo con Q-Learning. Este método se justifica porque el problema de coordinación semafórica tiene una estructura de decisión secuencial con retroalimentación demorada. Esto quiere decir que el efecto de cambiar un offset no es de inmediato sino que se hace conforme los vehículos avanzan por la calle. Este método es de gran utilidad porque permite aprender a decidir correctamente sin necesidad de un modelo explícito del entorno.

Espacio de Estados

Para este sistema, el estado se define de la siguiente manera:

$$S = (cola_JDLV, cola_AHU, cola_RIC, cola_PRI)$$

Donde cada componente es un valor entre $\{0, 1, 2\}$ obtenido de la función de discretización.

El valor 0 representa que hay menos de 3 vehículos detenidos, el 1 que hay entre 3 y 6 vehículos detenidos y el 2 el caso en el que se tienen 7 o más vehículos detenidos. Esto nos da un espacio resultante de $3^4 = 81$ estados posibles. El aprendizaje ocurre mediante un proceso de entrenamiento en el que se visita un subconjunto de estos estados. Las

combinaciones de cola no son igualmente probables debido a las tasas de demanda del corredor.

Espacio de Acciones

Las acciones para cada uno de los episodios es un vector de los cuatro offsets aplicados a cada semáforo del corredor. Se muestra de la siguiente manera:

$$A = (offset_JDLV, offset_AHU, offset_RIC, offset_PRI)$$

Donde el offset de JDLV es cero y los demás son perturbaciones alrededor del offset teórico calculado con la siguiente ecuación:

$$offset_{cruce} = (distancia_cruce / velocidad_sincronía) * FPS$$

Para este cálculo se utiliza una velocidad de sincronía de 40 km/hr y 25 FPS. Las perturbaciones posibles con $\{0, -20, +20, -40, +40\}$ frames, que en segundos representan $\{0, -0.8, 0.8, -1.6, 1.6\}$, y se aplican también con reducción modular para garantizar que cada perturbación sea consistente respecto al offset base. El número total de acciones que se tienen es de $5^3 = 125$. Los offsets teóricos en segundos, para una velocidad de 40 km/h (11 m/s) son:

- Junco de la Vega: 0.0 segundos (referencia)
- Ahuehuetes (AHU): Distancia de 193.8 m, offset de 17.44 segundos.
- Ricardo Covarrubias (RIC): Distancia de 580.0 m, offset de 52.2 segundos.
- Boulevard Primavera (PRI): Distancia de 965.1 m, 86.85 segundos

Función de Recompensa

La función de recompensa es fundamental para el correcto funcionamiento del modelo. En este caso, fue diseñada para capturar el objetivo de onda verde, en donde se prioriza premiar el flujo continuo y se penaliza la congestión de vehículos. La función se describe como:

$$R = 100 \cdot (vsp) + 50 \cdot (ve) - 0.5 \cdot (pt) - 5 \cdot (cp) - 0.1 \cdot (tp)$$

Donde:

- $vsp = veh_sin_parada$
- $ve = veh_exitosos$
- $pt = paradas_totales$
- $cp = cola_promedio$
- $tp = tiempo_promedio$

En esta parte, el primer término (100) corresponde a los vehículos que logran completar el corredor sin paradas para determinar la efectividad de la onda verde. Así mismo, la recompensa 70 es asignada por el número de vehículos que completan el recorrido exitosamente. Los dos términos restantes actúan como penalizaciones a las paradas totales, la congestión y el tiempo de recorrido.

Reglas de Decisión

Para la exploración y explotación se sigue una estrategia de ϵ -greedy que utiliza decaimiento exponencial con los parámetros: $\epsilon_0 = 1$, $\epsilon_{min} = 0.05$, factor de decaimiento = 0.995.

La actualización de la tabla Q utiliza la ecuación de Bellman:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \cdot \max_{a'} Q(s', a') - Q(s, a)]$$

Donde se utiliza una tasa de aprendizaje $\alpha = 0.15$ y un factor de descuento de $\gamma = 0.9$. Asimismo, se realizó la implementación de un early stopping con paciencia de 70 episodios para evitar el sobreentrenamiento. Esto hizo que hubiera una detención del entrenamiento antes de los 200 episodios definidos, ya que la recompensa dejó de mejorar en más de 5 puntos durante 50 episodios consecutivos.

2.3 Estrategia de Coordinación para la Onda Verde

La estrategia de coordinación implementada busca conseguir la onda verde a lo largo del corredor completo por offsets. Esta coordinación es lograda con la asignación de un offset temporal a cada uno de los semáforos, definido como el desfase en frames con el que cada semáforo inicia su fase verde respecto a la primera intersección, Junco de la Vega. La velocidad de sincronía es definida en 40 km/h (11.11 m/s) y 25 FPS.

Se implementó una función de actualización que para cada cruce calcula el tiempo local y se determina la fase activa. Una condición necesaria para el cumplimiento de la coordinación de la onda verde es que todas las intersecciones compartan el mismo ciclo de operación en segundos (ISPREVI, 2020). Con un ciclo de 240 frames (9.6s) y un Split verde de 96 frames (3.84s), la coordinación se actualiza cada frame. Los offsets resultantes se reducen módulo el ciclo de operación para mantener todos los valores dentro del rango de tiempo lógico. Los offsets base quedan:

- Junco de la Vega (JDLV): 0 frames (referencia)
- Ahuehuetes: 119 frames (4.76 s)
- Luis Elizondo: 27 frames (1.08)

Estos valores garantizan que un auto con origen en Junco de la Vega a 40 km/h, salga con luz verde y llegue a cada intersección siguiente en el momento en el que el semáforo que le corresponde también se encuentre en verde. Con la base de tiempo local definida por el ciclo de frames, se identifica qué semáforo se encuentra en verde, seguido por un periodo de todo rojo.

Se presentan tres escenarios de coordinación distintos que permiten comparar el desempeño bajo distintos parámetros:

- Sin coordinación: Todos los offsets son cero y los semáforos actúan con una fase inicial aleatoria sin comunicación, manteniendo tiempos desiguales por cruce (50, 45,

40 y 60 frames de verde respectivamente). Esto simula el estado de los semáforos sin coordinación, y sirve como base de comparación.

- Coordinación manual: Offsets teóricos calculados con la distancia y velocidad entre cada uno de los cruces. Este caso representa el óptimo teórico alcanzable.
- Q-Learning: Offsets que se aprenden por la tabla Q en el mejor episodio de entrenamiento. Se ajustan alrededor del offset físico ideal por medio de las perturbaciones ya mencionadas, considerando una velocidad de 40 km/h. Este escenario es capaz de adaptarse a condiciones reales, puesto que no depende exclusivamente del cálculo teórico.

3. Resultados

3.1 Modelado del entorno y del corredor

El corredor de estudio se reconstruyó a escala métrica a partir de coordenadas GPS reales de las cinco referencias del eje Fernando García Roel, convertidas a un sistema local en metros mediante una aproximación plana centrada en la intersección Junco de la Vega-Fernando García Roel. Sobre esta geometría, se trazaron las trayectorias vehiculares con curvas Bézier cuadráticas y cúbicas, lo que permite reproducir giros con movimiento continuo y realista. Las distancias simuladas corresponden a las reales: 193.8 m de JDLV a Ahuehuetes, 386.2 m de Ahuehuetes a Luis Elizondo y 385.4 m de Luis Elizondo a Primavera, para una longitud total de 965 m.




Figura 3.1. Reconstrucción a escala del corredor Fernando García Roel con las cuatro intersecciones modeladas y las trayectorias vehiculares generadas mediante curvas de Bézier.

Los vehículos se inyectan al corredor desde nueve puntos de entrada, con tasas de demanda calibradas a las observadas en la realidad para las horas de 7:00 a 10:00 am, recuperadas de los croquis proporcionados por la Organización Socio Formadora. La interacción entre agentes vehiculares se gestiona mediante un protocolo anticollisiones, en el cual cada vehículo evalúa si existe otro a menos de 8 metros de distancia en su dirección de movimiento. Esto se calcula mediante el producto punto entre su vector de dirección y el vector hacia el cercano. La regla de decisión para descongestionar pelotones que puedan surgir a causa de lo anterior es que el vehículo con menor progreso en su ruta cederá el paso.




Figura 3.2. Diagrama espacio-tiempo con coordinación (abajo) y sin coordinación (arriba) por onda verde. La banda diagonal de fase verde permite a un pelotón cruzar el corredor con un número reducido de detenciones.

Una vez configurado el entrenamiento a través de un aprendizaje Q-learning, mencionado anteriormente en el documento, este se detuvo en el episodio 129 al no registrar mejoras superiores a 5 puntos durante 70 episodios consecutivos. El mejor desempeño se alcanzó en el episodio 59, con una recompensa máxima de 2091.3 puntos. Durante el entrenamiento, el agente visitó sólo 9 de los 81 estados posibles concentrados en configuraciones de cola alta en los primeros tres cruces. Por lo tanto, el resultado central del aprendizaje es que los offsets aprendidos coinciden con los offsets físicos ideales del corredor modelado; es decir, que el agente fue capaz de reproducir por sí solo la solución analítica de la onda verde.

Cruce	Offset aprendido (frames)	Offset aprendido (s)	Offset físico ideal (s)
JDLV	0	0.00	0.00
Ahuehuetes	436	17.44	17.44
Ricardo	1305	51.40	52.20
Primavera	2171	86.44	86.44

Tabla 3.1. Offsets aprendidos por el agente Q-Learning (mejor episodio) frente a los offsets físicos

3.2 Comparación cuantitativa de escenarios

Se evaluaron tres configuraciones de offsets sobre una ejecución de 900 frames cada una: (1) sin coordinación (offsets nulos), (2) coordinación manual (ideal) por onda física y (3) Q-Learning SMA con los offsets del mejor episodio. Es importante mencionar que los offsets aprendidos por el agente coinciden con los offsets físicos ideales, dado que los escenarios (2) y (3) producen métricas idénticas. La Tabla 3.2 resume las métricas y la Tabla 3.3 las variaciones porcentuales respecto al escenario base.

Escenario	Recompensa	Vehículos exitosos	Paradas totales	Paradas/veh. h.	Tiempo prom. (s)
Sin coordinación	1504.02	19	13	0.68	8.54
Coordinación manual (ideal)	1644.05	22	19	0.86	11.03
Q-Learning SMA	1644.05	22	19	0.86	11.03

Tabla 3.2. Métricas de desempeño de los tres escenarios evaluados (corrida de 900 frames). Los escenarios coordinados coinciden porque el agente aprendió los offsets físicos ideales.

Escenario	Δ Recompensa	Δ Vehículos	Δ Paradas/veh.	Δ Tiempo
Coordinación manual (ideal)	+9.31 %	+15.78 %	+26.22 %	+29.09 %
Q-Learning SMA	+9.31 %	+15.78 %	+26.22 %	+29.09 %

Tabla 3.3. Variación porcentual de los escenarios coordinados respecto al escenario sin coordinación. Un valor positivo en Paradas/veh. y Tiempo indica un aumento (el código los reporta como reducción con signo negativo).




Figura 3.3. Comparación de vehículos atendidos, paradas promedio, tiempo de viaje promedio y recompensa entre los tres escenarios.

En síntesis, la coordinación (manual ideal y Q-learning, equivalentes) elevó el número de vehículos atendidos en 15.78% (de 19 a 22) y la recompensa global en 9.31% respecto a la operación sin coordinación. En la misma ejecución, sin embargo, es importante considerar que el tiempo de viaje promedio aumentó 29.09% (de 8.54s a 11.03s) y las paradas por

vehículo, 26.22% (de 0.68 a 0.86). Este último valor permanece por debajo de una parada por vehículo, que corresponde a un criterio con el que el sistema clasifica la onda verde como efectiva, dado que en un corredor coordinado se espera que la mayoría de los vehículos del flujo principal atraviesen cruces deteniéndose la menor cantidad de veces. La figura 3.2 muestra el diagrama tiempo-espacio de los escenarios con y sin coordinación, cuya interpretación se desarrolla en la sección de Discusión y Análisis.

4. Discusión y Análisis

En el escenario sin coordinación los cuatro agentes semafóricos operan de forma completamente independiente, con offsets en cero y distintos tiempos de verde por cruce. Esta es la simulación de un corredor sin un plan semafórico coordinado. El resultado es el peor registrado en términos de recompensa con 1504.02 puntos, 19 vehículos completados, 0.68 paradas promedio por vehículo y un tiempo de recorrido de 8.54s. La razón de estos resultados se deben a que cuando un pelotón de vehículos sale de JDLV en verde, no existe garantía de que al llegar al siguiente cruce tenga el camino libre, dado que no se define una relación temporal con su momento de salida, generando colas. Esto se ve ilustrado en el diagrama tiempo-espacio del escenario sin coordinación (Figura 3.2), donde las fases semafóricas siguen tiempos independientes. Aunque varios vehículos alcanzan a avanzar hasta Ricardo o Primavera, no logran completar el corredor, quedando con trayectorias inconclusas.

El hallazgo más relevante del proyecto es que el agente Q-Learning aprendió de forma autónoma los offsets físicos ideales del corredor (tabla 3.1). Partiendo de una política aleatoria y explorando perturbaciones alrededor de los offsets físicos, el agente identificó como mejor configuración precisamente la onda verde analítica (0/14.32/49.08/85.28 s), con una diferencia despreciable de un solo cruce (Ricardo: 51.40s aprendido vs 52.20s físico, menos de un segundo). En consecuencia, el escenario Q-Learning y el escenario de coordinación manual ideal son indistinguibles en sus métricas. Este resultado valida dos cosas a la vez: que el modelo físico está bien planteado (la solución analítica que se le dio al agente como referencia es efectivamente la óptima dentro del espacio explorado) y que el aprendizaje por refuerzo es capaz de recuperar esa solución sin conocerla previamente. Que el agente lo lograra visitando solo 9 de 81 estados sugiere que en este corredor la política óptima depende mucho más de la geometría (distancia y velocidad de sincronía) que del estado instantáneo de las colas (una vez fijados los offsets correctos), presentando un buen desempeño frente a la configuración de cola observada.

El diagrama tiempo-espacio de Q-Learning es una confirmación visual de la efectividad de la coordinación puesto que las trayectorias del líder del pelotón y de la cola atraviesan el corredor completo de 965 metros en aproximadamente 85 segundos sin encontrarse con ninguna banda roja a lo largo de su recorrido. Se aprecia que el pelotón encuentra verde en JDLV al inicio, en Ahuehuetes alrededor de $t = 22s$, en Ricardo alrededor de $t = 60s$ y finalmente alcanza Primavera en $t = 85 s$, aproximadamente. Estos tiempos son consistentes con las distancias reales divididas entre la velocidad de sincronía, mientras que la banda

diagonal continua es la representación visual del avance vehicular generado y de que la sincronización por offsets funciona exitosamente.

Respecto a la operación sin coordinación, la onda verde mejoró el rendimiento de vehículos atendidos (+15.78 %, de 19 a 22) y la recompensa global (+9.31%). Sin embargo, el tiempo de viaje promedio y las paradas por vehículo aumentaron (+29.09 % y +26.22 %). Esta aparente paradoja admite una explicación de fondo, la cual es la siguiente:

1. Efecto de composición sobre los promedios: El tiempo y las paradas se promedian únicamente sobre los vehículos que completan su viaje dentro del horizonte de 900 frames. Sin coordinación, sólo concluyen 19 vehículos, probablemente los que enfrentan trayectos más cortos o favorables. Con coordinación concluyen 22, incorporando vehículos que, antes no alcanzaban a terminar y que al hacerlo, aportan tiempos y paradas mayores. El aumento de los promedios, entonces, se puede considerar como una mejora real de la capacidad (el sistema atiende más demanda).
2. La onda verde prioriza el eje principal: Los offsets sincronizan el eje principal, pero los flujos de cruce y los giros conflictivos pueden esperar más, lo que eleva el tiempo y las paradas promedio del conjunto.

En conjunto, la coordinación incrementa la capacidad del corredor; el costo aparente en tiempo y paradas promedio se explica en buena medida por el cambio en la composición de los vehículos que logran completar el trayecto y queda como punto a verificar con una evaluación estadística más sólida.

Un resultado que es importante discutir es la formación de colas. Los escenarios coordinados (tanto el ideal como el aprendido), registran valores más altos en las paradas promedio por vehículo (0.86 vs 0.68) respecto al escenario sin coordinación. Mientras que ‘Sin coordinación’ sólo concluye 19 vehículos, probablemente tienen trayectos más cortos, mientras que ‘Con coordinación’ concluyen 22, incluyendo vehículos que no alcanzan a terminar, sugiriendo que el corredor modelado, al ser la arteria principal, tiene mayor demanda. Adicionalmente se tiene que la onda verde sincroniza precisamente el eje principal, pero no a los vehículos provenientes de accesos laterales, por lo que no forman parte del pelotón sincronizado, agregando paradas que más bien están relacionadas con la gran cantidad de orígenes del entorno modelado.

Una de las limitaciones que acota la generalidad de los resultados del modelo, es que el estado del agente solo observa colas discretizadas en tres niveles, sin considerar información de fase ni de tasa de llegada; esto corresponde a que el entrenamiento visitó apenas 9 de los 81 estados posibles. Así mismo, en los escenarios evaluados en una sola ejecución no se modelan peatones ni se detallan todos los escenarios conflictivos. Sin embargo, a pesar de las limitaciones, podemos considerar que los objetivos planteados se cumplieron. Esto se debe a que se diseñó e implementó el modelo multiagente del corredor García Roel y se evaluó la viabilidad de la onda verde (Objetivo 1). Además, se modelaron vehículos y semáforos como agentes y se calcularon offsets a partir de distancia y velocidad de sincronía (Objetivo 2); y se generó y evaluó el diagrama espacio-tiempo, midiendo colas, espera y ancho de banda (Objetivo 3). Adicionalmente, el agente de aprendizaje por refuerzo recuperó de forma

autónoma los offsets de onda verde, lo que confirma la coherencia entre el modelo físico y la política aprendida.

5. Conclusiones y Trabajo Futuro

5.1 Conclusiones

El proyecto logra cumplir con el objetivo de la aplicación de Q-Learning para la toma de decisiones para agentes semafóricos y vehículos para desarrollar una propuesta para el corredor urbano. La coordinación por offsets es lo principal para asegurar la onda verde y el mejor funcionamiento de todos los cruces. Al introducir las coordinaciones teóricas se vio una mejora contundente de 11% en vehículos atendidos y 16.5% en paradas promedio respecto al escenario sin coordinación. El Q-Learning integra una optimización adicional para el modelo que demuestra una mejora de 27.8% en vehículos atendidos y 22.7% en las paradas promedio.

El agente con Q-Learning orientaba la toma de decisiones de manera coherente, aprendiendo los mejores desfases temporales con un viaje teórico entre cruces de 40 km/h. Esto valida que se logra integrar la lógica de la onda verde para una gran cantidad de vehículos, mostrando que el aprendizaje por refuerzo puede entender y optimizar los patrones de tránsito. Además, la función de recompensa prioriza correctamente el flujo sin paradas, generando un sistema que maximiza el volumen de automóviles que pasan a pesar de que aumentó un poco el tiempo de espera comparado al de los offsets teóricos. Este es un hallazgo importante ya que se podría optar por un enfoque de minimizar el tiempo de espera pero no garantiza que se cumpla el máximo flujo de carros en los cruces.

El aprendizaje por refuerzo Q-Learning nunca converge a una política determinista (al ser un proceso estocástico) porque el entorno cambia en cada episodio (la inyección de vehículos es aleatoria). El early stopping fue una herramienta útil para detener el entrenamiento cuando la mejora marginal por episodio fue despreciable, evitando tiempo de cómputo innecesario sin sacrificar calidad de la política aprendida.

5.2 Trabajo Futuro

Este trabajo puede extenderse a futuro. Esta sección ilustra diferentes limitaciones y futuras implementaciones que pueden incorporarse con la finalidad de extender el desarrollo. En primer lugar, el trabajo está enfocado solamente en este corredor de la zona de Distrito Tec, para tener una mejor simulación podría implementar en más cruces y calles que se encuentren alrededor de esta zona. De esta manera, se podría tener un mejor entendimiento del comportamiento de la movilidad urbana en la zona y poder modelar una coordinación más compleja en la zona. En segundo lugar, se podría mejorar el trabajo si se consiguen los datos de la demanda de estas calles en tiempo real. Así sería posible observar cómo la demanda cambia a través de las horas y de la semana, así como la adaptación del agente para tomar distintas decisiones. En tercer lugar, podría trabajarse explorando otros algoritmos de aprendizaje más complejos para compararlos con el desempeño actual del modelo.

Referencias

- Bouktif, S., Cheniki, A., Ouni, A., & El-Sayed, H. (2023). Deep reinforcement learning for traffic signal control with consistent state and reward design approach. *Knowledge-Based Systems*, 267, 110440.
<https://doi.org/10.1016/j.knosys.2023.110440>
- Gobierno de Mendoza. (2025, 31 de marzo). Buscan agilizar el tránsito en Mendoza: cómo es el sistema inteligente que implementará el gobierno. Los Andes.
<https://www.losandes.com.ar/sociedad/buscan-agilizar-el-transito-mendoza-como-es-el-sistema-inteligente-que-implementara-el-gobierno-n5943269>
- Intriago-Pazmiño, M., Villafuerte-Mayorga, G., & Jara-Riofrío, M. (2023). Incidencia económica por congestión vehicular: Un análisis enfocado en los transportistas del servicio público urbano. *Ingeniería e Innovación*, 14(2), 56–68.
<https://www.redalyc.org/journal/5885/588575261004/html/>
- Mamani-Quispe, B., Chura-Quispe, G., Aybar-Bellido, J., & Vilca-Pareja, L. (2022). Congestión vehicular y contaminación ambiental en Lima Metropolitana. *Logos Ciencia & Tecnología*, 14(1), 152–165.
- ISPREVI. (2020). *La onda verde*. Isprevi.Org.
<https://isprevi.org/2020/08/13/la-onda-verde>

Anexos

Anexo A. Presentación

El siguiente anexo contiene el enlace a la presentación que fue mostrada al Socio Formador. Contiene un resumen de la implementación y algunos resultados anteriores.

<https://canva.link/vye6rz7sz6zahwf>

Anexo B. Código Fuente

Se incluye el código fuente completo del notebook de Python utilizado para la implementación del sistema multiagente.

<https://drive.google.com/file/d/1eqYV6gfEJaFHOFQgJwgVVeqZmoPnuQy/view?usp=sharing>

Anexo C. Material complementario

Se presentan los procesos de ejecución, gráficas y resultados obtenidos en la ejecución realizada para el presente informe. Éstos complementan el desarrollo presente en este reporte, principalmente proporcionando evidencias visuales del entorno modelado. Su propósito es ofrecer un respaldo detallado de los resultados discutidos.

1.0

Se presenta el cálculo de los Offsets ideales, realizados con base en las distancias entre cruces considerando la velocidad de 40 km/h (11.11 m/s):

```

... Offsets físicos base (frames):
    JDLV: 0 frames = 0.00 s
    AHUEHUETES: 436 frames = 17.44 s
    RICARDO: 1305 frames = 52.20 s
    PRIMAVERA: 2171 frames = 86.84 s

Espacio de acciones: 125

Q-Table inicializada como diccionario vacío (lazy).
Estado ejemplo: (2, 2, 2, 0)

```

Se reporta la tabla de parámetros finales de ejecución de Q-Learning. Asimismo, se muestra el cálculo de los estados posibles y el espacio de acciones:

PARÁMETROS Q-LEARNING

```

Episodios entrenados : 200
Frames por episodio : 900 (36 s)
Espacio de estados : 3^4 = 81 estados posibles
Estados visitados : 9
Espacio de acciones : 125 (5^3 perturbaciones)
Learning rate (α) : 0.15
Factor descuento (γ) : 0.9
ε final : 0.5212

```

Ejecución del algoritmo de aprendizaje por refuerzo Q-Learning. Se muestran cada 5 episodios ejecutados con el número de automóviles exitosos, las paradas, las recompensas, el estado, el parámetro épsilon, así como el tiempo que tomó cada evaluación. Es apreciable cómo se aplica efectivamente la técnica de regularización por parada temprana:

Ep 0/200	R= 1353.6	Exitosos= 18	Paradas= 18	ε=0.995	Estado=(2, 2, 2, 0)	58.4s
Ep 5/200	R= 721.1	Exitosos= 12	Paradas= 14	ε=0.970	Estado=(2, 2, 2, 0)	66.1s
Ep 10/200	R= 740.0	Exitosos= 13	Paradas= 18	ε=0.946	Estado=(2, 2, 1, 0)	56.0s
Ep 15/200	R= 1074.5	Exitosos= 19	Paradas= 24	ε=0.923	Estado=(2, 2, 2, 1)	62.1s
Ep 20/200	R= 1187.4	Exitosos= 16	Paradas= 16	ε=0.900	Estado=(2, 2, 1, 1)	65.6s
Ep 25/200	R= 717.4	Exitosos= 13	Paradas= 21	ε=0.878	Estado=(2, 2, 2, 0)	64.4s
Ep 30/200	R= 831.9	Exitosos= 16	Paradas= 19	ε=0.856	Estado=(2, 2, 2, 1)	77.1s
Ep 35/200	R= 594.5	Exitosos= 13	Paradas= 17	ε=0.835	Estado=(2, 2, 1, 0)	83.1s
Ep 40/200	R= 1512.5	Exitosos= 21	Paradas= 23	ε=0.814	Estado=(2, 2, 1, 0)	65.4s
Ep 45/200	R= 784.8	Exitosos= 15	Paradas= 16	ε=0.794	Estado=(2, 2, 2, 0)	78.8s
Ep 50/200	R= 1053.7	Exitosos= 16	Paradas= 16	ε=0.774	Estado=(2, 2, 1, 1)	52.4s
Ep 55/200	R= 947.4	Exitosos= 14	Paradas= 17	ε=0.755	Estado=(2, 2, 2, 0)	54.2s
Ep 60/200	R= 1280.2	Exitosos= 22	Paradas= 26	ε=0.737	Estado=(2, 2, 2, 0)	69.5s
Ep 65/200	R= 861.2	Exitosos= 14	Paradas= 15	ε=0.718	Estado=(2, 2, 2, 0)	58.5s
Ep 70/200	R= 1348.8	Exitosos= 17	Paradas= 14	ε=0.701	Estado=(2, 2, 2, 0)	62.2s
Ep 75/200	R= 884.9	Exitosos= 15	Paradas= 14	ε=0.683	Estado=(2, 2, 2, 0)	83.5s
Ep 80/200	R= 1019.1	Exitosos= 19	Paradas= 22	ε=0.666	Estado=(2, 2, 2, 1)	75.8s
Ep 85/200	R= 719.5	Exitosos= 12	Paradas= 10	ε=0.650	Estado=(2, 2, 2, 0)	64.6s
Ep 90/200	R= 1262.7	Exitosos= 17	Paradas= 15	ε=0.634	Estado=(2, 2, 1, 0)	61.5s
Ep 95/200	R= 982.5	Exitosos= 15	Paradas= 14	ε=0.618	Estado=(2, 2, 1, 0)	49.2s
Ep 100/200	R= 362.6	Exitosos= 12	Paradas= 17	ε=0.603	Estado=(2, 2, 2, 0)	89.8s
Ep 105/200	R= 1266.3	Exitosos= 19	Paradas= 22	ε=0.588	Estado=(2, 2, 1, 1)	65.4s
Ep 110/200	R= 1568.0	Exitosos= 24	Paradas= 29	ε=0.573	Estado=(2, 2, 2, 0)	133.4s
Ep 115/200	R= 1262.6	Exitosos= 18	Paradas= 21	ε=0.559	Estado=(2, 2, 2, 0)	87.8s
Ep 120/200	R= 681.9	Exitosos= 13	Paradas= 16	ε=0.545	Estado=(2, 2, 1, 0)	57.8s
Ep 125/200	R= 1190.4	Exitosos= 17	Paradas= 16	ε=0.532	Estado=(2, 2, 1, 1)	60.4s

Early stopping at episode 129 due to no improvement for 70 episodes.

```

=====
Entrenamiento terminado en 147.88 min
Estados visitados: 9
=====


```


Se generaron DataFrames de las comparativas entre los tres escenarios, detallando las métricas más importantes, así como las diferencias porcentuales respecto al escenario base ‘Sin coordinación’:

	escenario	recompensa	vehiculos_exitosos	paradas_totales	paradas_promedio	tiempo_promedio
0	Sin coordinación	1504.023041	19	13	0.684211	8.547368
1	Coordinación manual (ideal)	1644.052101	22	19	0.863636	11.034545
2	Q-Learning SMA	1644.052101	22	19	0.863636	11.034545

mejora_recompensa_%	mejora_vehiculos_%	reduccion_paradas_%	reduccion_tiempo_%
0.0000	0.000000	0.000000	0.000000
9.3103	15.789474	-26.223776	-29.098746
9.3103	15.789474	-26.223776	-29.098746

Con efectos de visualización, se generaron gráficos para facilitar las interpretaciones y comparaciones:





Anexo D. Repositorio del proyecto

Se presenta un repositorio del proyecto en GitHub que contiene todos los documentos desarrollados a lo largo del proyecto.

<https://github.com/AlejandroMtzPaez/AgentesInteligentes>